

# Plano — Assistente do LangNet (um agente que faz, dentro do LangNet, o que o Claude Code faz hoje)

Data: 01/10/2026 · Projeto de teste: BioByte Sentinela v5

## 1. O que se quer

Hoje o trabalho de conduzir um projeto pelo pipeline do LangNet é feito por uma sessão do Claude Code no terminal: ela carrega os documentos, dispara cada etapa, espera a geração, lê o resultado, confere no banco e nas telas, pede correções ao agente da etapa, aprova e segue. O objetivo é ter **esse mesmo papel dentro do próprio LangNet**:

- um ícone de chat no canto direito de qualquer tela do projeto abre um painel de conversa;
- quem conversa é o mesmo modelo (Claude Opus, pela assinatura Max, na máquina que já serve o LangNet);
- o assistente **faz** as coisas (gera, refina, compara, aprova, confere), não só responde;
- ele **lembra** de tudo o que já fez no projeto, no mesmo nível de contexto desta sessão;
- tudo fica registrado no projeto, como já acontece com as conversas de cada etapa;
- o modo manual continua existindo: cada etapa pode ser feita à mão ou pelo assistente.

## 2. O que já existe e foi conferido

| Peça                                                                       | Situação                                                                                                                                                                                                                                       |
|----------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ponte OpenAI-compatível do Claude (192.168.1.100:4443, modelo claude-code) | Funciona, sem custo por token. <b>Mas não executa ferramentas</b> (devolve texto mesmo quando recebe tools) e <b>não guarda estado</b> entre chamadas; sem fluxo, corta respostas grandes. Serve para gerar documentos, não para ser o agente. |
| Hub Sessões (/mnt/data1/progpython/gerenciadorsessoesclaude)               | Já dirige sessões do Claude Code com <code>claude -p --resume &lt;sessão&gt;</code> : o contexto vive no transcrito em disco, sem terminal aberto. É exatamente o mecanismo de memória desta sessão.                                           |
| LangNet: conversas por etapa                                               | Tabelas <code>specification_chat_messages</code> , <code>data_model_chat_messages</code> , <code>ui_spec_chat_messages</code> , <code>tool_chat_messages</code> etc. já registram cada pedido e resposta por projeto.                          |
| LangNet: API REST                                                          | Todas as etapas têm endpoints (gerar, refinar, versões, aprovar) — é o que esta sessão usa hoje, com o token de login.                                                                                                                         |


## 3. A decisão de arquitetura

**Recomendação: uma sessão do Claude Code por projeto, rodando na máquina do plano Max, acordada pelo LangNet a cada mensagem com `--resume`, e com as ações do LangNet oferecidas a ela como ferramentas por um servidor MCP.**

Por que esse caminho e não a ponte 4443:

- **Mesmo contexto que esta sessão.** O `--resume` reabre o transcrito inteiro; quando ele cresce, o próprio Claude Code compacta, como aqui. Não é preciso reinventar memória de conversa.
- **Ferramentas de verdade.** O Claude Code chama ferramentas MCP nativamente; a ponte não chama.
- **Sem custo por token**, pela assinatura Max — a mesma de hoje.
- **Já provado em casa** pelo Hub Sessões.

O caminho alternativo (ponte 4443 + um laço de agente escrito por nós, com ações em JSON no texto e a memória montada pelo LangNet a cada chamada) fica como plano B, caso o headless não possa rodar naquela máquina. Ele exige reimplementar contexto e compactação, e por isso fica pior.



## 4. As peças a construir

### 4.1 Serviço de sessões (na máquina Max)

Um serviço pequeno, com token (mesmo esquema da ponte 4443), que: - recebe {projeto, mensagem} e roda `claude -p --resume <sessão_do_projeto> --output-format stream-json` com a configuração MCP do LangNet e a lista de ferramentas permitidas; - cria a sessão na primeira mensagem do projeto e guarda o id; - devolve os eventos em fluxo: texto do modelo, chamada de ferramenta, resultado, fim; - garante **uma execução por projeto de cada vez** (fila), e permite interromper; - tem uma pasta de trabalho por projeto com um `CLAUDE.md` gerado pelo LangNet (ver 4.5).

Pode ser um módulo novo do Hub Sessões, que já tem o daemon e o `--resume`, em vez de um serviço do zero.

### 4.2 Servidor MCP "langnet" (as mãos do assistente)

Expõe as ações do LangNet como ferramentas, todas por cima da API REST que já existe:

| Grupo   | Ferramentas                                                                                                                                                                                                                                                                                   |
|---------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ler     | <code>estado_do_projeto</code> (etapas, versões, aprovações) · <code>ler_documento</code> (etapa, versão, trecho) · <code>comparar_versoes</code> (etapa, v1, v2) · <code>consultar_banco</code> (só leitura) · <code>ler_conversas_da_etapa</code>                                           |
| Fazer   | <code>carregar_documento</code> · <code>gerar_etapa</code> (etapa, origem, versão, instrução) · <code>refinar_etapa</code> (etapa, pedido) · <code>aprovar_versao</code> · <code>rodar_portao</code> · <code>gerar_codigo</code> · <code>implantar</code> · <code>rodar_casos_de_teste</code> |
| Esperar | <code>acompanhar_tarefa</code> (id) — as gerações levam minutos; a ferramenta devolve o andamento, e o painel mostra o progresso                                                                                                                                                              |
| Ver     | <code>capturar_tela</code> (rota) — foto da tela do LangNet ou do app gerado, para o modelo conferir o que o usuário veria                                                                                                                                                                    |

Regras do servidor: - **o programa executa, o modelo decide** (a regra que já vale no LangNet); - aprovar, implantar e apagar **pedem confirmação** no painel antes de rodar; - cada chamada fica registrada com quem pediu, o que entrou e o que saiu.

### 4.3 Backend do LangNet — router /assistant

- `POST /projects/{id}/assistant/messages` — envia a mensagem e devolve o fluxo de eventos (SSE);
- `GET /projects/{id}/assistant/messages` — histórico do projeto;
- `POST /projects/{id}/assistant/confirm/{acao}` — confirmação de ação sensível;
- `POST /projects/{id}/assistant/stop` — interromper.

Tabelas novas (migração 032): - `assistant_sessions` — projeto, id da sessão do Claude, estado, criado/atualizado; - `assistant_messages` — papel, texto, eventos de ferramenta, versões criadas ou aprovadas, data; - `assistant_project_memory` — fatos duráveis do projeto (decisões, regras, pendências), editáveis.

### 4.4 Frontend — o painel

- ícone de chat no canto direito do cabeçalho, em todas as telas dentro de um projeto;
- painel lateral (gaveta) com a conversa, a resposta chegando em fluxo e cada passo do agente visível ("gerando a especificação a partir dos requisitos v1...", "conferindo a tabela no banco...");
- botões de confirmar e cancelar quando o assistente pede para aprovar, implantar ou apagar;
- links diretos para a versão criada, a comparação e a tela afetada;
- o assistente sabe em que tela o usuário está e usa isso como contexto da mensagem.

### 4.5 Memória e contexto — "no mesmo nível desta sessão"

Três camadas, como aqui: 1. **Transcrito da sessão** (`--resume`): a conversa inteira, compactada automaticamente quando cresce; 2. **Memória do projeto** (`assistant_project_memory` → gerada como `CLAUDE.md` da pasta do projeto): o que precisa sobreviver a qualquer compactação — regras do pipeline (origem + versão → gerar → refinar → aprovar), decisões tomadas, pendências, lições (ex.: "não regerar para descobrir"); 3. **Estado real lido do banco** a cada pedido, pelas ferramentas: o assistente não confia na lembrança para saber em que versão cada etapa está — ele consulta.

## 5. Fases

| Fase | Entrega                                                                                                                                    | Como se prova                                                                                        |
|------|--------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| F0   | Prova de conceito: <code>claude -p --resume</code> na máquina Max com um servidor MCP de uma ferramenta ( <code>estado_do_projeto</code> ) | duas mensagens seguidas; a segunda lembra da primeira; a ferramenta devolve o estado real do BioByte |
| F1   | Serviço de sessões + router /assistant + migração 032                                                                                      | conversa pela API, registrada no banco, com fluxo                                                    |

| Fase | Entrega                                                                     | Como se prova                                                                                          |
|------|-----------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|
| F2   | Ferramentas de leitura (ler, comparar, consultar banco, conversas da etapa) | o assistente responde corretamente "em que versão está a especificação e o que mudou da v1 para a v2"  |
| F3   | Painel de chat no React                                                     | conversa pela tela, com os passos visíveis                                                             |
| F4   | Ferramentas de ação + confirmação + acompanhamento de tarefas longas        | o assistente refina o modelo de dados do BioByte por conversa e a versão nova aparece na tela da etapa |
| F5   | Memória do projeto e retomada                                               | fechar o navegador, voltar no dia seguinte: o assistente sabe onde parou                               |
| F6   | Captura de telas e bateria no app gerado                                    | o assistente confere a tela da tarefa e o resultado no banco, como esta sessão faz                     |
| F7   | Aceitação                                                                   | refazer pelo assistente uma etapa do BioByte já feita aqui e comparar o resultado                      |

## 6. Riscos e o que conferir antes

- **A máquina Max precisa ter o Claude Code instalado e logado** na assinatura (a ponte 4443 indica que sim, mas é a primeira coisa da F0).
- **Cotas do plano Max:** cada mensagem reabre o transcrito; sessões longas consomem mais. Limitar uma execução por projeto e acompanhar o uso.
- **Permissões:** a sessão do assistente roda **só com as ferramentas MCP do LangNet**, sem terminal livre na máquina do LangNet nem acesso de escrita ao banco fora das ações previstas.
- **Rede:** a máquina Max precisa alcançar o servidor MCP e a API do LangNet (rede local).
- **Gerações longas:** a mensagem não pode ficar presa minutos esperando; a ação devolve um id e o acompanhamento informa o andamento.
- **Falha não pode passar calada:** erro de ferramenta aparece como erro no painel, nunca como sucesso.

## 7. Próximo passo

Executar a **F0** (prova de conceito na máquina Max). Se o - - resume com MCP funcionar lá, o resto é construção; se não funcionar, cai-se no plano B (ponte 4443 + laço próprio) antes de construir qualquer tela.